

# TOOLKIT DE MUESTREO Y TEOREMA DEL LÍMITE CENTRAL



## EQUIPO:


- Alonso Corral Martha Julieta
- Leal Salguero Ari Iván
- Jiménez Cornejo Emanuel Adrián
- Diaz Garduño José Angel
- Franco Guzmán Alberto



# INTRODUCCIÓN

Es un simulador que toma poblaciones "desordenadas" y demuestra cómo, al promediarlas, se vuelven ordenadas y predecibles.


- **Objetivo:** Desarrollar un software interactivo que demuestre la convergencia a la normalidad de diversas distribuciones base.
- **Reto:** Demostrar que no importa de dónde vengan los datos, si tomamos suficientes muestras, siempre terminaremos en una campana de Gauss.



# TEOREMA DEL LÍMITE CENTRAL

**Establece que si se toman muestras suficientemente grandes de una población, las medias de las muestras tendrán una distribución normal , incluso si la población no tiene una distribución normal.**

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$



# MODELADO ESTADÍSTICO.

El modelado estadístico de nuestra aplicación se divide en tres componentes críticos: la definición de las poblaciones base, el proceso de muestreo aleatorio y la caracterización de la distribución resultante.

# DISTRIBUCIONES DE POBLACIÓN (ENTRADA).

Para demostrar que el TLC funciona independientemente de la forma original, modelamos tres escenarios:

- Distribución Uniforme ( $U[0, 1]$ ): Representa procesos equiprobables. Parámetros teóricos:  $\mu = 0.5$  y  $\sigma^2 = 1/12 \approx 0.0833$ .
- Distribución Exponencial ( $\lambda = 1$ ): Crucial para modelar tiempos de espera. Es una distribución no simétrica con  $\mu = 1$  y  $\sigma^2 = 1$ . Su asimetría representa el reto principal para la validación visual del TLC.
- Distribución Bernoulli ( $p = 0.5$ ): Modela eventos dicotómicos (éxito/fracaso). Permite observar cómo el promedio de valores discretos converge a una variable continua.

# EL TEOREMA DEL LÍMITE CENTRAL (PROCESO):

## MEDIA MUESTRAL

Es el promedio de un subconjunto de una muestra de datos extraído de una población más grande.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

## VARIANZA MUESTRAL

Es una medida de dispersión que representa la variabilidad de una serie de datos con respecto a su media.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

# ERROR ESTÁNDAR

Estima qué tanto se alejaría la media de tu muestra de la verdadera media de toda la población si repitieras el experimento muchas veces.

$$\frac{s}{\sqrt{n}}$$


# MONTE CARLO

Tipo de algoritmo computacional que utiliza muestreo aleatorio repetido para obtener la probabilidad de que se produzca un rango de resultados.

$$\begin{aligned}\bar{X}_n &\rightarrow \mu \\ n &\rightarrow \infty\end{aligned}$$


# UNIFORME

Probabilidad constante en un rango (Escenario base)




# EXPONENCIAL

Modela tiempos de espera (Escenario con asimetría).



# BERNOULLI

Eventos dicotómicos de éxito o fracaso (Escenario discreto).







# LENGUAJE Y LIBRERÍAS

**Lenguaje:** Python 3.10.

**Framework:** Streamlit para la interfaz de usuario reactiva.

**Procesamiento:** NumPy para cálculos vectorizados de alta velocidad.

**Visualización:** Matplotlib y SciPy Stats para el renderizado de densidades teóricas.

# TUTORIAL DE USO

**01**

Crear un nuevo archivo.

**02**

Abrir una terminal

**03**

Ejecutar `python -m venv env` en terminal y dar enter

**04**

Ejecutar `pip install streamlit numpy matplotlib scipy` en la terminal

**05**

Esperar a que lo descargue

**06**

Guarda el archivo en una carpeta

**07**

Para ejecutar el programa ejecuta `streamlit run <nombre de archivo>.py`

**08**


De primera vez pedirá correo escribir correo electrónico

# FUNCIONAMIENTO

**Entrada (Input):** Selección de distribución, tamaño de muestra (**n**) y número de experimentos (**N**).

**Procesamiento:** Muestreo aleatorio iterativo y cálculo de estadísticos descriptivos.

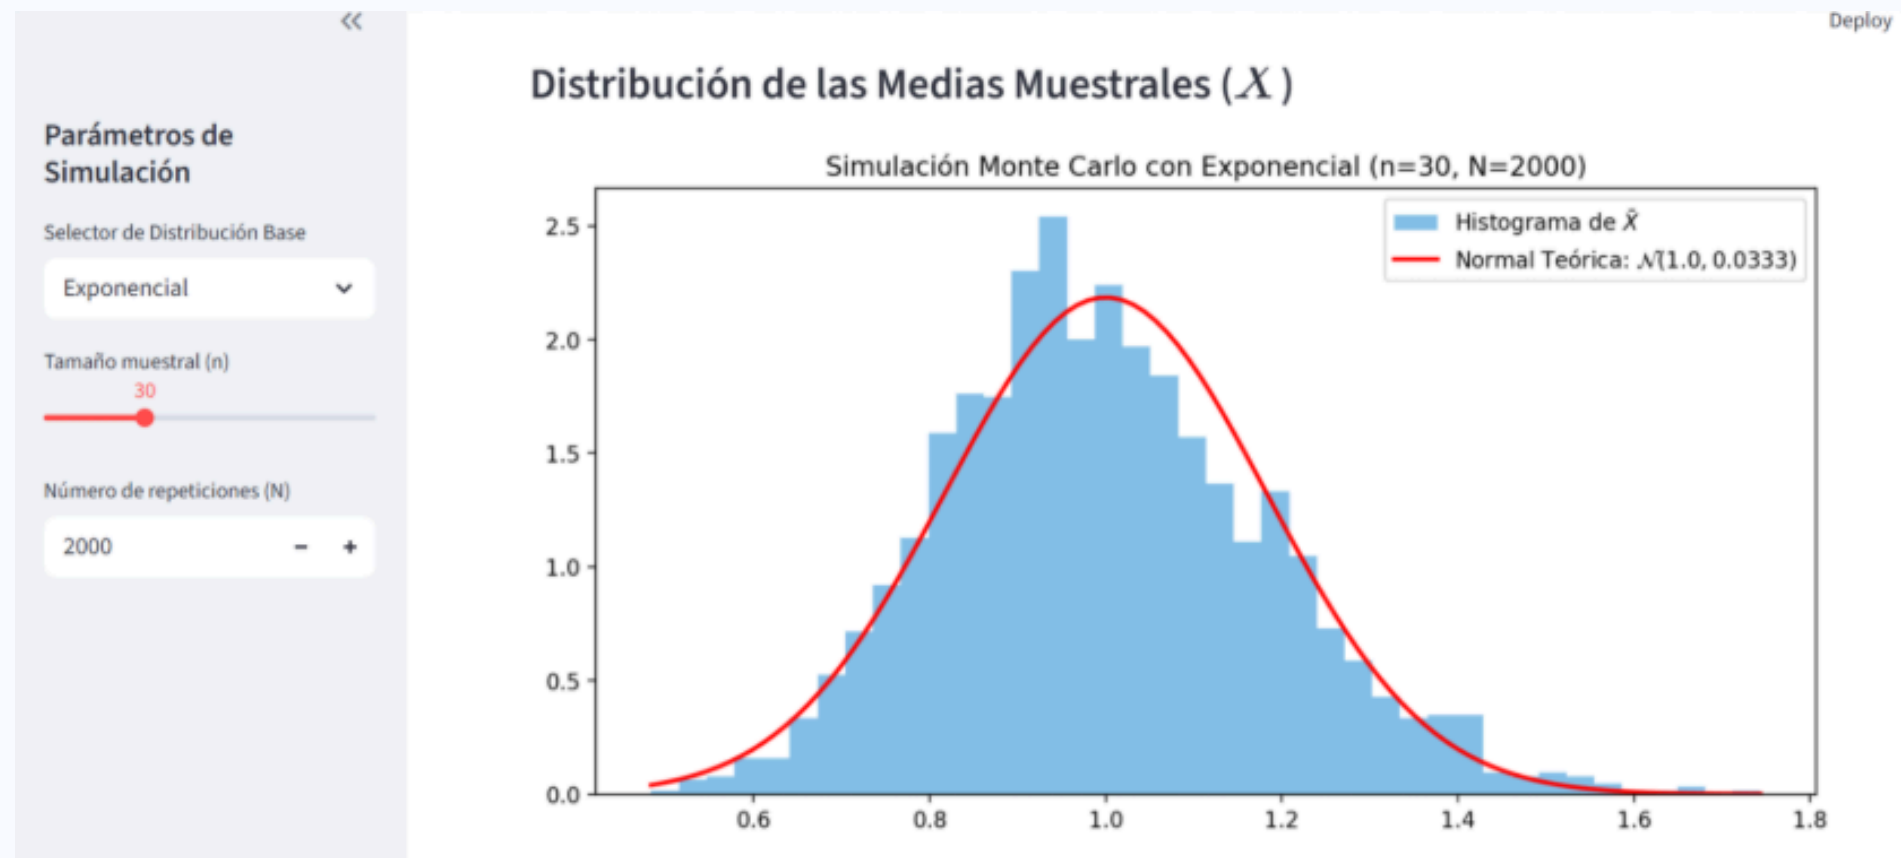
**Salida (Output):** Histograma de frecuencias relativas superpuesto con la curva normal teórica.



# I. VALIDACIÓN DE CONVERGENCIA (HISTOGRAMAS)

PRUEBA CON  $N=30$

PRUEBA CON  $N=2000$



OBSERVACION

A pesar de que la distribución exponencial original es altamente sesgada, el histograma de las medias muestrales (azul) se ajusta casi perfectamente a la curva Normal teórica

# 2. VALIDACIÓN NUMÉRICA

**El programa calcula la diferencia entre la teoría y la simulación.**

Ejemplo de ejecución:

Media de  $\bar{X}$ : 0.9982 (Teórica: 1.0000).

Varianza de  $\bar{X}$ : 0.0341 (Teórica:  $1/30 = 0.0333$ ).

La cercanía entre estos valores confirma que  $\bar{X}$  es un estimador insesgado y consistente.

## Resultados de la Simulación

Media de  $\bar{X}$ : 0.9991

Varianza de  $\bar{X}$ : 0.0342

## Valores Teóricos (TLC)

$\mu$  (esperada): 1.0000

$\sigma^2/n$  (varianza esperada): 0.0333

El Error Estándar (SE) actual es: 0.1826


# INTERVALO DE CONFIANZA

Es un rango de valores que, con un cierto nivel de probabilidad (confianza), contiene el verdadero valor de un parámetro poblacional desconocido (como la media) estimado a partir de datos de una muestra, ayudando a cuantificar la incertidumbre de la estimación puntual.

Se expresa como un límite inferior y superior, y su nivel (ej., 95%) indica cuántas veces el intervalo capturaría el valor real si se repitiera el muestreo muchas veces, ofreciendo una medida de precisión para la estimación



95% Interval




# 3. COBERTURA DE INTERVALOS DE CONFIANZA

Se implementó una visualización visual para validar la cobertura del 95%.

**Caso A (n pequeño):** Con  $n=5$  en una distribución Exponencial, el sistema arroja una advertencia, mostrando una cobertura real menor al 93% y múltiples líneas rojas en el gráfico, indicando que la aproximación normal falló.


**Caso B (n adecuado):** Con  $n=30$  o mayor, el indicador de cobertura se torna verde (cercano al 95%), validando el TLC.

Visualización de los primeros 50 intervalos (Verde = Contiene a  $\mu$ , Rojo = No contiene)



# CONCLUSIONES

El Teorema del Límite Central es valioso porque se aplica a muchos casos, la simulación computacional hace más fácil aprender estadística y, además, un buen tamaño de muestra permite obtener resultados más confiables.





# REFERENCIAS

Walpole, R. E., et al. (2012). Probabilidad y estadística para ingeniería y ciencias.

Documentación de Streamlit y NumPy (2024).

Notas de curso: Probabilidad y Estadística, ESCOM.

Wackerly, D., Mendenhall, W., y Scheaffer, R. (2010)  
Estadística Matemática con Aplicaciones.